

# **Dokumen Laporan Teknis Komprehensif**

## **Coding Camp 2026 powered by DBS Foundation**

**ID Tim Capstone Project:** [CC26-PSU182]

**Judul Proyek** : [Sustainable Living & Responsible Consumption.]

**Tema yang Dipilih** : [PilahYuk!]

**Nama Advisor Capstone:**

1. [RC26-359] - [Dr. David, M.Cs., M.Kom] - [19 & 23 Mei 2026]

**List Anggota** :

1. (CDCC318D6X2160) - (Sarah Aulia Rahmah)- (Data Scientist) - **[Aktif]**
2. (CDCC318D6X2161) - (Nurul Santi Hafifah)- (Data Scientist) - **[Aktif]**
3. (CACC318D6Y2217) - (Muhamad Lutfi)- (AI Engineer) - **[Aktif]**
4. (CFCC318D6Y2276) - (Sirrul Fatih Ahdiat)- (Full-Stack Web Developer) - **[Aktif]**
5. (CACC318D6Y2519) - (Guna Fatala)- (AI Engineer) - **[Aktif]**  
(CFCC318D6Y2872) - (Dafa Rizqy)- (Full-Stack Web Developer) - **[Aktif]**

# 1. PENDAHULUAN

## 1.1 Latar Belakang

Peningkatan volume sampah global telah menjadi salah satu tantangan lingkungan dan sosial paling mendesak di era modern. Konsumsi yang terus meningkat dan urbanisasi telah menyebabkan akumulasi limbah yang signifikan, menuntut solusi inovatif dan berkelanjutan untuk pengelolaan sampah. Dalam konteks ini, penerapan teknologi kecerdasan buatan (AI), khususnya Computer Vision dan Machine Learning, menawarkan potensi transformatif untuk otomatisasi identifikasi dan klasifikasi jenis sampah. Sistem klasifikasi otomatis ini dapat secara substansial meningkatkan efisiensi pemilahan sampah, mengurangi biaya operasional, dan memfasilitasi proses daur ulang yang lebih efektif.

Namun, keberhasilan dan kinerja model AI sangat bergantung pada kualitas dataset yang digunakan untuk pelatihan. Dataset mentah seringkali mengandung berbagai anomali seperti missing values, entri duplikat, inkonsistensi, dan class imbalance, yang dapat secara signifikan menghambat kemampuan model untuk belajar dan menggeneralisasi secara efektif. Oleh karena itu, proses data wrangling yang sistematis dan Exploratory Data Analysis (EDA) menjadi krusial untuk mengubah dataset mentah menjadi format yang bersih, terstruktur, dan model-ready. Data wrangling melibatkan serangkaian operasi untuk membersihkan, mengubah, dan memperkaya data, sementara EDA berfokus pada penemuan pola, deteksi anomali, dan pengujian hipotesis melalui teknik visualisasi dan statistik.

Proyek ini bertujuan untuk mengatasi permasalahan kualitas data ini dengan mengembangkan workflow yang komprehensif untuk data wrangling dan EDA pada dataset gambar sampah daur ulang. Selain itu, untuk memfasilitasi eksplorasi dan monitoring data yang intuitif, sebuah dashboard interaktif dikembangkan menggunakan Streamlit. Dashboard ini tidak hanya menyajikan visualisasi analitik tetapi juga memungkinkan pengguna untuk memvalidasi kualitas dataset secara visual dan mengidentifikasi area untuk perbaikan lebih lanjut. Dengan demikian, proyek ini berkontribusi pada pengembangan sistem pengelolaan sampah cerdas yang lebih efisien, akurat, dan berkelanjutan, dengan menyediakan dataset berkualitas tinggi dan alat analisis yang user-friendly untuk komunitas riset dan pengembangan AI.

## **2. PROBLEM DISCOVERY**

Dataset publik yang diperoleh dari platform seperti Kaggle seringkali tidak siap pakai dan memerlukan pra-pemrosesan ekstensif. Berdasarkan observasi awal terhadap dataset gambar sampah daur ulang, beberapa kendala utama yang dapat menghambat pengembangan model AI telah diidentifikasi:

### **2.1 Missing Value**

Analisis awal mengungkapkan bahwa beberapa metadata gambar memiliki nilai kosong (NaN) atau informasi yang tidak lengkap pada atribut-atribut penting. Keberadaan missing values ini dapat menyebabkan error selama tahap preprocessing dan pelatihan model, serta berpotensi menimbulkan inkonsistensi dalam analisis statistik. Penanganan missing values memerlukan strategi yang tepat, seperti imputasi atau penghapusan, tergantung pada proporsi dan signifikansi data yang hilang.

### **2.2 Data Duplicate**

Terdapat sejumlah file gambar dan entri metadata yang terduplikasi dalam dataset. Duplikasi data dapat memunculkan bias yang signifikan selama proses pelatihan model, karena model mungkin “menghafal” pola dari data yang berulang secara tidak proporsional, alih-alih mempelajari fitur yang dapat digeneralisasi. Identifikasi dan penghapusan duplikat sangat penting untuk memastikan integritas dan representativitas dataset.

### **2.3 Struktur Folder yang Tidak Konsisten**

Dataset memiliki struktur direktori yang tidak terorganisir dengan baik, termasuk keberadaan beberapa folder sementara dan penamaan path yang tidak konsisten. Struktur yang tidak teratur ini menyulitkan proses sinkronisasi antara metadata dan file gambar, serta menghambat otomatisasi pipeline pemrosesan data. Konsolidasi dan standarisasi struktur folder diperlukan untuk memfasilitasi akses dan manajemen data yang efisien.

### **2.4 Class Imbalance**

Distribusi jumlah gambar pada masing-masing kategori sampah (kelas) tidak merata. Beberapa kelas memiliki jumlah sampel yang jauh lebih besar dibandingkan kelas lainnya. Ketimpangan ini dapat menyebabkan model Machine Learning cenderung bias terhadap kelas mayoritas, menghasilkan akurasi yang tinggi pada kelas tersebut tetapi kinerja yang buruk pada kelas minoritas. Strategi penanganan class

imbalance, seperti oversampling, undersampling, atau penyesuaian bobot kelas, perlu dipertimbangkan.

## **2.5 Kurangnya Visualisasi data**

Dataset belum dilengkapi dengan sistem visualisasi terpadu yang dapat membantu eksplorasi distribusi data, analisis korelasi, dan validasi kualitas dataset secara interaktif. Ketiadaan alat visualisasi ini menyulitkan pengguna dan pengembang untuk memahami karakteristik data secara mendalam dan memantau dampak dari proses data wrangling. Pengembangan dashboard interaktif menjadi solusi yang diperlukan untuk mengatasi keterbatasan ini.

### **3. Tujuan Proyek**

#### **3.1 Pembersihan dan Penataan Dataset**

Melakukan data wrangling yang komprehensif untuk membersihkan dataset dari missing values, duplikasi, dan inkonsistensi, serta merapikan struktur folder agar siap digunakan untuk proses pemodelan.

#### **3.2 Eksplorasi Karakteristik Data**

Melakukan Exploratory Data Analysis (EDA) mendalam untuk memahami distribusi kelas, korelasi antar fitur numerik, dan polapola tersembunyi dalam dataset.

#### **3.3 Identifikasi dan Mitigasi Class Imbalance**

Mengidentifikasi tingkat ketimpangan distribusi data antar kelas dan merumuskan strategi mitigasi yang tepat, seperti data augmentation, untuk meningkatkan representasi kelas minoritas.

#### **3.4 Standarisasi Metadata Label**

Menghasilkan metadata yang valid, konsisten, dan terdokumentasi dengan baik, serta membuat label mapping JSON untuk memastikan standarisasi label antara dataset, dashboard, dan model AI.

#### **3.5 Pengembangan Dashboard Interaktif**

Membangun dashboard analisis berbasis Streamlit yang intuitif dan user-friendly sebagai alat utama untuk eksplorasi, monitoring, dan validasi kualitas dataset.

#### **3.6 Penyediaan Dataset Model-Ready**

Menyiapkan dataset akhir yang telah divalidasi dan siap digunakan (model-ready) untuk pengembangan model Computer Vision tingkat lanjut, seperti Convolutional Neural Networks (CNN) atau YOLOv8.

## **4. Data Gathering**

Tahap pengumpulan data merupakan fondasi dari setiap proyek berbasis data. Dalam proyek ini, dataset gambar sampah daur ulang diperoleh dari sumber publik yang terkemuka, yaitu platform Kaggle. Kaggle adalah repositori dataset dan notebook yang luas, sering digunakan oleh peneliti dan praktisi Machine Learning untuk berbagai aplikasi.

### **4.1 Sumber Data**

Dataset yang digunakan berasal dari kompetisi atau proyek yang dipublikasikan di Kaggle, yang secara spesifik menyediakan koleksi gambar sampah dari berbagai kategori material. Pemilihan Kaggle sebagai sumber data didasarkan pada ketersediaan dataset yang relevan, ukuran yang memadai, dan potensi untuk mereplikasi hasil. Meskipun demikian, dataset dari sumber publik seringkali memerlukan validasi dan pembersihan ekstensif sebelum dapat digunakan secara efektif untuk modelling.

### **4.2 Karakteristik Data**

Dataset ini secara fundamental terdiri dari dua komponen utama yang saling terkait:

#### **4.2.1 Data Gambar**

Data gambar berupa koleksi file citra digital (misalnya, dalam format JPG atau PNG) yang secara hierarkis dikelompokkan ke dalam folder-folder terpisah. Setiap folder merepresentasikan kategori sampah tertentu, seperti 'Kaca', 'Plastik', 'Kertas', 'Kardus', 'Logam', 'Organik', 'Pakaian', dan 'Residu'. Struktur folder ini secara implisit berfungsi sebagai label kelas awal untuk setiap gambar. Resolusi dan kualitas gambar bervariasi, yang memerlukan perhatian khusus selama tahap preprocessing untuk memastikan konsistensi dan kesesuaian untuk pelatihan model Computer Vision.

#### **4.2.2 Data Metadata**

Selain data gambar, dataset juga dilengkapi dengan file metadata, umumnya dalam format CSV (Comma Separated Values). File ini berisi informasi deskriptif untuk setiap gambar, yang mencakup atribut-atribut penting seperti:

- Nama file gambar: Identifikasi unik untuk setiap citra.
- Lokasi/path file: Jalur relatif atau absolut ke file gambar dalam sistem penyimpanan.

- Label kategori: Kategori sampah yang terkait dengan gambar, seringkali direpresentasikan sebagai string teks.
- Ukuran gambar: Dimensi piksel (lebar dan tinggi) dari citra.
- Informasi atribut numerik lainnya: Atribut tambahan yang mungkin relevan, seperti tanggal pengambilan gambar, sumber, atau anotasi khusus.

Metadata ini berfungsi sebagai jembatan penting antara file citra mentah dan proses analisis data. Konsistensi dan akurasi metadata sangat krusial karena akan digunakan untuk melabeli, memfilter, dan mengorganisir data gambar selama data wrangling dan EDA. Ketidaksesuaian antara metadata dan data gambar dapat menyebabkan error dalam pipeline Machine Learning dan mengurangi keandalan model yang dihasilkan.

## 5. Assessing Data

Tahap penilaian data adalah langkah krusial dalam data wrangling yang bertujuan untuk mengidentifikasi masalah kualitas data sebelum melakukan intervensi pembersihan. Proses ini dilakukan secara sistematis menggunakan Jupyter Notebook ( `Analisis_Data_Tahap_1.ipynb` ) untuk eksplorasi awal dan dokumentasi temuan. Penilaian ini mencakup pemeriksaan struktur data, deteksi missing values, duplikasi, dan analisis anomali kelas.

### 5.1 Pemeriksaan Struktur Data

Pemeriksaan awal difokuskan pada kesesuaian antara metadata yang disediakan dan file gambar aktual dalam direktori penyimpanan. Aspek-aspek yang diperiksa meliputi:

- a. **Konsistensi Nama File:** Memastikan bahwa nama file gambar yang tercatat dalam metadata sesuai dengan nama file fisik di sistem. Ketidaksesuaian dapat menyebabkan kegagalan dalam memuat gambar atau menghubungkannya dengan metadata yang benar.
- b. **Kesesuaian Jumlah File Gambar:** Memverifikasi bahwa jumlah entri dalam metadata cocok dengan jumlah file gambar yang ada. Disparitas dapat mengindikasikan file yang hilang atau entri metadata yang tidak memiliki gambar terkait.
- c. **Struktur Direktori Penyimpanan:** Mengevaluasi organisasi folder dan sub-folder untuk memastikan konsistensi dan kemudahan akses. Struktur yang tidak terorganisir dapat mempersulit proses data loading dan pipeline pemrosesan.
- d. **Validitas Format Data:** Memeriksa format file gambar (misalnya, JPG, PNG) dan format metadata (misalnya, CSV) untuk memastikan integritas dan kompatibilitas dengan alat analisis yang akan digunakan.

### 5.2 Deteksi Missing Value

Deteksi missing values dilakukan pada atribut-atribut kunci dalam metadata. Missing values dapat muncul karena berbagai alasan, seperti kesalahan input, kegagalan ekstraksi, atau data yang memang tidak tersedia. Keberadaan missing values dapat berdampak negatif pada analisis dan modeling:

- **Ketidakkonsistenan Analisis:** Missing values dapat mendistorsi statistik deskriptif dan inferensial, menyebabkan kesimpulan yang salah.
- **Error saat Preprocessing:** Banyak algoritma Machine Learning tidak dapat

menangani missing values secara langsung, sehingga memerlukan penanganan khusus seperti imputasi atau penghapusan baris/kolom.

- Penurunan Kualitas Model Machine Learning: Jika tidak ditangani dengan benar, missing values dapat mengurangi akurasi dan generalisasi model.

Metode deteksi melibatkan penghitungan persentase missing values per kolom dan visualisasi pola missingness untuk memahami distribusinya.

### 5.3 Deteksi Duplikasi Data

Duplikasi data, baik pada file gambar maupun entri metadata, dapat menyebabkan bias dalam dataset dan overfitting pada model. Proses deteksi duplikasi mencakup:

- Nama File Gambar yang Berulang: Mengidentifikasi file gambar dengan nama yang sama tetapi mungkin berada di lokasi berbeda atau memiliki konten yang identik.
- Metadata Duplikat: Mendeteksi baris metadata yang identik atau sangat mirip, yang mungkin merepresentasikan entri data yang sama.
- Path Direktori yang Redundan: Mengidentifikasi path file yang mengarah ke gambar yang sama atau duplikat.

Penanganan duplikasi sangat penting untuk memastikan setiap observasi dalam dataset adalah unik dan independen, sehingga model dapat belajar dari variasi data yang sebenarnya.

### 5.4 Analisis Anomali Kelas

Analisis anomali kelas berfokus pada pemeriksaan label kategori dan distribusinya. Ini mencakup:

- Inkonsistensi Penamaan Label: Mengidentifikasi variasi penulisan untuk kategori yang sama (misalnya, 'Plastik' vs. 'plastik').
- Label Sementara yang Tidak Relevan: Mendeteksi label yang mungkin digunakan selama proses anotasi awal tetapi tidak relevan untuk tujuan klasifikasi akhir.
- Distribusi Kelas yang Tidak Seimbang: Menghitung frekuensi setiap kelas untuk mengidentifikasi class imbalance, di mana beberapa kategori memiliki jumlah sampel yang jauh lebih sedikit. Ini adalah masalah umum dalam dataset dunia nyata dan dapat menyebabkan model bias terhadap kelas mayoritas.
- Kebutuhan Penambahan Kategori Baru: Berdasarkan eksplorasi, ditemukan

kebutuhan untuk menambahkan kategori baru seperti Organik dan Clothes untuk memperkaya representasi variasi jenis sampah dalam dataset. Penambahan ini dilakukan untuk meningkatkan cakupan dan robustness model klasifikasi di masa mendatang.

Penilaian ini memberikan gambaran menyeluruh tentang kualitas dataset dan menjadi dasar untuk perencanaan tahap pembersihan data.

## **6. Data Cleaning**

Tahap pembersihan data adalah proses sistematis untuk memperbaiki anomali yang teridentifikasi selama penilaian data, memastikan dataset menjadi bersih, konsisten, dan siap untuk modeling. Proses ini melibatkan beberapa langkah kunci:

### **6.1 Konsolidasi Struktur Folder**

Untuk mengatasi inkonsistensi struktur folder, seluruh file gambar dipusatkan ke dalam satu direktori utama yang terstandardisasi, yaitu `images/`. Folder-folder sementara atau yang tidak diperlukan, seperti `clean_images_filtered/` dan `clean_images_merged/`, dieliminasi. Langkah konsolidasi ini memberikan beberapa manfaat signifikan:

- **Struktur Dataset yang Lebih Rapi:** Mempermudah navigasi dan pengelolaan file gambar.
- **Sinkronisasi Metadata yang Lebih Mudah:** Memastikan bahwa path file dalam metadata secara akurat mereferensikan lokasi fisik gambar, mengurangi error saat data loading.
- **Integrasi yang Efisien:** Mempermudah integrasi dataset dengan aplikasi dashboard dan pipeline model AI, karena semua gambar dapat diakses dari satu lokasi yang konsisten.

### **6.2 Penyelarasan Label Kelas**

Proses relabeling dilakukan untuk memastikan seluruh kategori sampah memiliki penamaan yang konsisten dan terstandardisasi. Ini melibatkan:

- **Normalisasi Teks:** Mengubah semua label menjadi format yang seragam (misalnya, huruf kecil, tanpa spasi ekstra).
- **Pemetaan Ulang Kategori:** Menggabungkan kategori yang serupa atau memperbaiki kesalahan penulisan. Sebagai contoh, jika ada label 'Plastik' dan 'plastik', keduanya akan disatukan menjadi 'Plastik'.
- **Penambahan Kategori Baru:** Berdasarkan analisis anomali kelas, kategori baru seperti 'Organik' dan 'Clothes' ditambahkan untuk memperkaya dataset dan meningkatkan representasi variasi jenis sampah. Penambahan ini dilakukan dengan mengidentifikasi gambar yang relevan dan menetapkan label yang sesuai.

Setelah penyelarasan, dataset akhir terdiri dari 8 kelas utama yang didefinisikan dengan jelas:

| No | Kategori |
|----|----------|
| 1  | Clothes  |
| 2  | Kaca     |
| 3  | Kardus   |
| 4  | Kertas   |
| 5  | Logam    |
| 6  | Organik  |
| 7  | Plastik  |
| 8  | Residu   |

Standardisasi label ini sangat penting untuk menjaga konsistensi selama proses pelatihan model Machine Learning, memastikan bahwa model belajar dari representasi kelas yang akurat dan seragam.

### 6.3 Sinkronisasi Metadata

Metadata diperbarui secara komprehensif untuk mencerminkan perubahan yang dilakukan pada data gambar dan label kelas. Proses ini melibatkan:

- Penghapusan Data Duplikat: Entri metadata yang teridentifikasi sebagai duplikat dihapus untuk memastikan setiap baris merepresentasikan observasi unik.
- Perbaikan Path Direktori Gambar: Path file dalam metadata diperbarui agar sesuai dengan struktur folder yang telah dikonsolidasi di images/ .
- Penyelarasan Label Kategori: Label kategori dalam metadata disesuaikan dengan label kelas yang telah distandardisasi.
- Validasi File yang Tersedia: Setiap entri metadata divalidasi terhadap keberadaan file gambar fisik yang direferensikannya. Entri metadata yang tidak memiliki file gambar terkait akan dihapus.

Hasil akhir dari proses sinkronisasi ini disimpan dalam file `clean_sampah_metadata_updated.csv` . File ini menjadi sumber metadata utama yang telah lolos validasi kualitas data dan siap digunakan untuk analisis lebih lanjut.

### 6.4 Pembuatan Mapping Label JSON

Untuk memastikan standardisasi dan konsistensi label di seluruh pipeline (antara dataset, dashboard, dan model AI), sebuah file `label_map.json` dibuat. File ini berfungsi sebagai kamus pemetaan antara nama kategori sampah (string) dan indeks numerik (integer). Contoh struktur mapping adalah sebagai berikut:

```
{  
  "Clothes": 0,  
  "Kaca": 1,  
  "Kardus": 2,  
  "Kertas": 3,  
  "Logam": 4,  
  "Organik": 5,  
  "Plastik": 6,  
  "Residu": 7  
}
```

Pemetaan ini sangat penting untuk model Machine Learning yang biasanya memerlukan input label dalam format numerik, serta untuk memastikan bahwa visualisasi pada dashboard menggunakan representasi label yang sama dengan yang digunakan oleh model. Ini juga mempermudah penambahan kategori baru di masa mendatang dengan hanya memperbarui file JSON ini.

## **7. Exploratory Data Analysis**

Exploratory Data Analysis (EDA) adalah tahap krusial setelah data wrangling yang bertujuan untuk memahami karakteristik dataset secara lebih mendalam, mengidentifikasi pola, mendeteksi anomali, dan menguji hipotesis awal. EDA dilakukan menggunakan kombinasi teknik statistik dan visualisasi data untuk mendapatkan insight yang akan memandu proses modeling.

### **7.1 Analisis Distribusi Kelas**

Analisis distribusi kelas adalah langkah pertama dalam EDA untuk dataset klasifikasi. Ini melibatkan penghitungan frekuensi atau jumlah gambar pada masing-masing kategori sampah. Tujuan utama dari analisis ini adalah:

- Mengidentifikasi Ketimpangan Distribusi Data: Memvisualisasikan sebaran jumlah sampel di antara kelas-kelas. Jika ada perbedaan signifikan, ini menunjukkan adanya class imbalance.
- Menentukan Kebutuhan Data Augmentation: Jika class imbalance teridentifikasi, analisis ini membantu menentukan kelas mana yang memerlukan data augmentation (penambahan data buatan) untuk menyeimbangkan dataset dan mencegah model bias terhadap kelas mayoritas.
- Mengevaluasi Kesiapan Dataset untuk Modeling: Distribusi kelas yang seimbang atau setidaknya dipahami adalah indikator penting kesiapan dataset untuk pelatihan model Machine Learning.

Hasil analisis menunjukkan bahwa beberapa kelas memiliki jumlah data yang jauh lebih sedikit dibandingkan kelas lainnya. Misalnya, kelas 'Residu' mungkin memiliki jumlah gambar yang sangat sedikit dibandingkan 'Plastik' atau 'Kertas'. Ketimpangan ini mengindikasikan perlunya strategi penyeimbangan data, seperti oversampling pada kelas minoritas atau undersampling pada kelas mayoritas, untuk memastikan model dapat belajar secara efektif dari semua kategori.

### **7.2 Analisis Korelasi Numerik**

Analisis korelasi numerik dilakukan terhadap atribut-atribut numerik yang ada dalam metadata, seperti ukuran gambar (lebar, tinggi), rasio aspek, atau fitur-fitur lain yang mungkin diekstraksi. Manfaat dari analisis korelasi meliputi:

- Mengidentifikasi Hubungan Antar Fitur: Menemukan sejauh mana dua atau lebih variabel numerik bergerak bersama. Korelasi positif menunjukkan bahwa ketika

satu variabel meningkat, yang lain juga cenderung meningkat, dan sebaliknya untuk korelasi negatif.

- Menemukan Pola Tertentu dalam Karakteristik Gambar: Misalnya, apakah ada korelasi antara ukuran gambar dan kategori sampah tertentu, atau antara rasio aspek dan jenis material.
- Menentukan Atribut yang Relevan untuk Modeling: Atribut dengan korelasi tinggi terhadap label kelas atau atribut lain yang penting dapat menjadi kandidat fitur yang kuat untuk model, sementara atribut dengan korelasi rendah mungkin kurang informatif.

Visualisasi matriks korelasi, seringkali dalam bentuk heatmap, sangat membantu dalam memahami hubungan statistik antar variabel secara lebih intuitif. Setiap sel dalam heatmap menunjukkan koefisien korelasi antara dua variabel, dengan warna yang mengindikasikan kekuatan dan arah korelasi. Ini memungkinkan identifikasi cepat terhadap fitur-fitur yang saling bergantung atau fitur-fitur yang mungkin redundan.

### **7.3 Analisis Kesiapan Modelling**

Tahap akhir dari EDA adalah analisis kesiapan modeling, yang bertujuan untuk memastikan bahwa dataset telah memenuhi standar minimum dan siap untuk digunakan dalam proses Machine Learning. Proses ini mencakup rekapitulasi dan validasi akhir dari langkah-langkah data wrangling dan EDA:

- Penghapusan Atribut Tidak Relevan: Atribut dalam metadata yang teridentifikasi tidak memiliki nilai prediktif atau tidak relevan untuk tujuan modeling akan dihapus untuk mengurangi dimensi data dan noise.
- Penyaringan Data Redundan: Memastikan bahwa semua duplikasi data telah dihilangkan sepenuhnya dari dataset.
- Standardisasi Label: Memverifikasi bahwa semua label kelas telah distandardisasi dan konsisten sesuai dengan `label_map.json`.
- Validasi File Gambar: Melakukan pemeriksaan akhir untuk memastikan bahwa semua path file gambar dalam metadata mengarah ke file fisik yang valid dan dapat diakses.

Hasil akhir dari tahap ini disimpan dalam file `model_ready.csv`. File ini merepresentasikan dataset final yang telah melalui proses data wrangling dan EDA

yang ketat, menjadikannya siap untuk digunakan dalam pengembangan model klasifikasi gambar. Dataset ini diharapkan memiliki kualitas tinggi, konsisten, dan bebas dari anomali yang dapat menghambat kinerja model AI.

## **8. Pengembangan Dashboard Streamlit**

Sebagai implementasi akhir dari proyek ini, sebuah dashboard analisis interaktif dikembangkan menggunakan Streamlit. Streamlit adalah framework Python open-source yang memungkinkan pembuatan aplikasi web data dengan cepat dan mudah, tanpa memerlukan keahlian front-end yang ekstensif. Dashboard ini dirancang untuk menyediakan antarmuka yang intuitif bagi pengguna untuk mengeksplorasi dataset, memantau kualitas data, dan mendapatkan insight dari hasil data wrangling dan EDA. File utama untuk dashboard ini adalah `dashboard.py`. Dashboard ini dikembangkan dengan tujuan utama untuk membantu pengguna dalam:

- **Eksplorasi Dataset:** Memungkinkan pengguna untuk menelusuri dan memahami karakteristik dataset secara visual.
- **Pemantauan Distribusi Data:** Menyediakan visualisasi real-time tentang sebaran kelas dan atribut lainnya.
- **Tampilan Visualisasi Analitik:** Menampilkan grafik dan chart yang relevan dari hasil EDA.
- **Akses Contoh Gambar per Kategori:** Memungkinkan pengguna untuk melihat sampel gambar dari setiap kategori sampah untuk validasi visual.

### **8.1 Ringkasan Statistik**

Bagian ringkasan statistik pada dashboard menampilkan metrik utama dataset secara real-time. Informasi ini sangat penting untuk memberikan gambaran cepat dan informatif tentang kondisi dataset tanpa perlu melakukan analisis manual melalui notebook. Metrik yang ditampilkan membantu proses evaluasi awal terhadap kesiapan data sebelum digunakan pada tahap modeling maupun deployment sistem klasifikasi sampah berbasis AI. Metrik-metrik tersebut meliputi:

- **Total Jumlah Gambar:** Menunjukkan ukuran keseluruhan dataset.
- **Total Kategori Aktif:** Jumlah kelas sampah yang unik dalam dataset.
- **Jumlah Metadata Valid:** Indikator kualitas metadata, menunjukkan berapa banyak entri metadata yang lengkap dan konsisten.
- **Status Dataset Model-Ready:** Sebuah indikator biner atau kualitatif yang menunjukkan apakah dataset telah memenuhi semua kriteria pembersihan dan siap untuk modeling.

### **8.2 Visualisasi Distribusi Kelas**

Visualisasi distribusi kelas adalah komponen kunci dari dashboard ini, yang memungkinkan pengguna untuk memahami komposisi dataset secara grafis. Visualisasi interaktif ini dapat menampilkan:

- Jumlah Gambar per Kategori: Biasanya direpresentasikan dalam bentuk bar chart atau pie chart, menunjukkan jumlah absolut gambar untuk setiap kelas sampah.
- Ketimpangan Distribusi Kelas: Secara visual menyoroti kelas-kelas yang memiliki jumlah sampel yang jauh lebih sedikit atau lebih banyak dibandingkan yang lain, mengkonfirmasi temuan dari EDA.
- Perbandingan Antar Kategori: Memungkinkan perbandingan langsung antara frekuensi kelas yang berbeda, membantu dalam identifikasi class imbalance.

Grafik ini sangat membantu pengguna dalam memahami kondisi dataset secara cepat dan membuat keputusan yang tepat mengenai strategi data augmentation atau penyeimbangan kelas.

### **8.3 Analisis Korelasi**

Untuk atribut numerik dalam metadata, dashboard menyediakan visualisasi analisis korelasi, umumnya dalam bentuk heatmap. Heatmap ini secara visual menunjukkan hubungan antar variabel metadata, dengan intensitas warna yang merepresentasikan kekuatan dan arah korelasi (positif atau negatif). Visualisasi ini mempermudah interpretasi pola statistik pada dataset, memungkinkan pengguna untuk:

- Mengidentifikasi fitur-fitur yang saling berkorelasi kuat.
- Menemukan potensi redundansi antar fitur.
- Mengevaluasi relevansi fitur-fitur tertentu terhadap label kelas.

### **8.4 Galeri Sampel Gambar**

Fitur galeri interaktif adalah bagian penting untuk validasi visual. Pengguna dapat melihat contoh gambar dari setiap kategori sampah secara langsung. Ini memungkinkan verifikasi visual terhadap kualitas dan konsistensi dataset, serta memastikan bahwa gambar telah diklasifikasikan dengan benar. Kategori yang tersedia dalam galeri ini mencerminkan kelas-kelas yang telah distandardisasi:

- Clothes
- Kaca
- Kardus
- Kertas

- Logam
- Organik
- Plastik
- Residu

## **8.5 Business Insight**

Selain visualisasi data mentah, dashboard juga menampilkan insight penting yang diperoleh dari hasil data wrangling dan EDA. Insight ini disajikan dalam format yang mudah dipahami dan dapat mencakup:

- Kelas dengan Jumlah Data Paling Sedikit: Menyoroti kelas-kelas minoritas yang mungkin memerlukan perhatian khusus untuk data augmentation.
- Potensi Bias Model Akibat Imbalance: Memberikan peringatan tentang risiko bias model jika class imbalance tidak ditangani.
- Kondisi Kualitas Metadata: Ringkasan tentang seberapa baik metadata telah dibersihkan dan distandardisasi.
- Rekomendasi Pengembangan Dataset: Saran-saran konkret untuk perbaikan dataset di masa mendatang, seperti pengumpulan data tambahan untuk kelas minoritas atau penambahan fitur baru.

## 9. Teknologi yang Digunakan

Proyek ini memanfaatkan stack teknologi berbasis Python yang kuat dan populer dalam ekosistem Data Science dan Machine Learning. Pemilihan teknologi ini didasarkan pada keandalan, komunitas yang besar, dan ketersediaan pustaka yang kaya untuk pemrosesan data dan visualisasi.

### 9.1 Python

Digunakan sebagai bahasa pemrograman utama dalam proyek karena memiliki sintaks yang sederhana, mudah dipahami, dan didukung oleh banyak pustaka untuk kebutuhan *Data Science* serta *Machine Learning*. Python juga menjadi standar industri dalam pengembangan analisis data karena fleksibel dan memiliki komunitas yang sangat luas.

### 9.2 Pandas

Berperan dalam proses pengolahan dan manipulasi data. Library ini menyediakan struktur data bernama *DataFrame* yang memudahkan proses pembersihan data, transformasi data, pengelompokan, hingga analisis data secara lebih terstruktur dan efisien.

### 9.3 NumPy

Digunakan untuk mendukung operasi numerik dan komputasi ilmiah. Library ini memungkinkan pengolahan array multidimensi serta berbagai operasi matematika kompleks dengan performa yang cepat dan efisien, sehingga sangat membantu dalam proses analisis data.

### 9.4 Matplotlib Seaborn

Digunakan untuk kebutuhan visualisasi data. Matplotlib berfungsi sebagai dasar pembuatan grafik dan plot, sedangkan Seaborn menyediakan tampilan visual yang lebih menarik dan informatif. Kedua library ini membantu dalam proses Exploratory Data Analysis (EDA) untuk memahami pola dan distribusi data.

### 9.5 Streamlit

Dimanfaatkan untuk membangun dashboard atau aplikasi web interaktif berbasis Python. Dengan Streamlit, hasil analisis data dapat ditampilkan dalam bentuk antarmuka yang mudah digunakan sehingga pengguna dapat melakukan eksplorasi data secara langsung melalui web.

### 9.6 Jupyter Notebook

Digunakan sebagai lingkungan kerja interaktif untuk analisis dan eksplorasi data. Platform ini memudahkan proses eksperimen, dokumentasi kode, serta visualisasi

hasil analisis dalam satu tempat sehingga sangat cocok digunakan selama tahap data wrangling dan EDA.

## **9.7 JSON**

Digunakan sebagai format penyimpanan data untuk standarisasi label mapping. Format ini ringan, mudah dibaca, dan membantu menjaga konsistensi data, terutama dalam pemetaan antara label kelas dan indeks numerik di seluruh proses pipeline analisis maupun machine learning.

## **10. Hasil dan Dampak Proyek**

### **10.1 Hasil Utama**

Proyek ini telah berhasil mencapai tujuan-tujuannya dan menghasilkan beberapa deliverables utama yang krusial untuk pengembangan model AI selanjutnya:

- a. Dataset Gambar yang Bersih dan Terstruktur: Kumpulan file citra yang telah diorganisir dalam struktur direktori yang konsisten, bebas dari duplikasi, dan siap untuk diakses oleh pipeline data loading.
- b. Metadata yang Tervalidasi dan Sinkron: File CSV yang berisi informasi deskriptif yang akurat, lengkap, dan sepenuhnya tersinkronisasi dengan file gambar fisik, memastikan integritas data.
- c. File Dataset Siap Modeling ( `model_ready.csv` ): Dataset final yang telah melalui semua tahap pembersihan dan EDA, memenuhi standar kualitas untuk pelatihan model Machine Learning.
- d. Standardisasi Label ( `label_map.json` ): Kamus pemetaan yang memastikan konsistensi representasi kelas antara dataset, dashboard, dan model AI.
- e. Dashboard Visualisasi Interaktif: Aplikasi Streamlit yang fungsional dan userfriendly untuk eksplorasi, monitoring, dan validasi dataset secara real-time.

### **10.2 Dampak Proyek**

Implementasi workflow data wrangling dan EDA yang sistematis ini memberikan dampak positif yang signifikan terhadap keseluruhan siklus hidup pengembangan model AI:

- a. Peningkatan Kualitas Dataset: Mengubah data mentah yang berantakan menjadi dataset berkualitas tinggi yang andal dan konsisten.
- b. Pengurangan Risiko Bias Model: Dengan mengidentifikasi dan merencanakan mitigasi untuk class imbalance, proyek ini membantu mencegah pengembangan model yang bias terhadap kelas mayoritas.
- c. Kemudahan Eksplorasi Data: Dashboard interaktif memfasilitasi pemahaman yang lebih dalam tentang karakteristik data, memungkinkan pengambilan keputusan yang lebih baik terkait strategi modeling.
- d. Dukungan Pengembangan Sistem Klasifikasi Otomatis: Menyediakan fondasi data yang solid untuk melatih model Computer Vision yang akurat untuk klasifikasi sampah.
- e. Fondasi Pengembangan AI Berbasis Computer Vision: Menetapkan standar dan pipeline yang dapat direplikasi untuk proyek-proyek AI serupa di masa mendatang.

## **11. Penutup**

### **11.1 Kesimpulan**

Proyek data wrangling dan Exploratory Data Analysis (EDA) ini telah berhasil mengubah dataset gambar sampah daur ulang mentah yang tidak terstruktur menjadi dataset yang bersih, terdokumentasi dengan baik, dan siap digunakan untuk kebutuhan pemodelan Machine Learning. Melalui serangkaian tahapan yang sistematis mulai dari Data Gathering, Assessing, Cleaning, hingga EDA kualitas dataset telah meningkat secara signifikan. Peningkatan ini terlihat jelas dari sisi konsistensi label, validitas metadata, dan struktur penyimpanan file yang lebih terorganisir.

Selain itu, pengembangan dashboard berbasis Streamlit telah berhasil menyediakan media visualisasi interaktif yang sangat berharga. Dashboard ini mempermudah proses monitoring kualitas data dan eksplorasi karakteristik dataset secara real-time, menjembatani kesenjangan antara data mentah dan insight yang dapat ditindaklanjuti. Hasil akhir proyek, yang mencakup dataset model-ready, metadata tervalidasi, dokumentasi dataset, dan dashboard analitik interaktif, menjadi fondasi yang kuat dan esensial untuk pengembangan sistem klasifikasi sampah pintar berbasis AI di masa mendatang. Proyek ini menegaskan bahwa pra-pemrosesan data yang teliti adalah prasyarat mutlak untuk keberhasilan implementasi Machine Learning di dunia nyata.

Proyek ini secara meyakinkan menunjukkan bahwa proses data wrangling dan EDA memiliki peran yang sangat fundamental dan tidak terpisahkan dalam keberhasilan pengembangan sistem kecerdasan buatan berbasis Computer Vision. Dataset yang bersih, terstruktur, dan terdokumentasi dengan baik adalah prasyarat mutlak untuk menghasilkan model klasifikasi yang akurat, andal, dan bebas bias. Melalui kombinasi workflow data engineering yang ketat, exploratory data analysis yang mendalam, dan visualisasi interaktif menggunakan Streamlit, proyek ini telah berhasil menghadirkan solusi awal yang solid menuju terwujudnya sistem pengelolaan sampah cerdas yang lebih modern, efisien, dan berkelanjutan. Keberhasilan proyek ini meletakkan dasar yang kokoh untuk inovasi lebih lanjut dalam penerapan AI untuk pelestarian lingkungan.

### **11.2 Rekomendasi Pengembangan Lanjutan**

Untuk memaksimalkan potensi dataset dan dashboard yang telah dikembangkan, beberapa rekomendasi pengembangan lanjutan diusulkan:

- a. Data Augmentation

Untuk mengatasi masalah class imbalance yang teridentifikasi selama EDA, penerapan teknik data augmentation sangat direkomendasikan, khususnya pada kelas minoritas. Teknik ini melibatkan pembuatan variasi buatan dari gambar yang ada untuk meningkatkan jumlah sampel pelatihan tanpa perlu mengumpulkan data baru.

b. Integrasi Model AI ke Dashboard

Dashboard Streamlit saat ini berfungsi sebagai alat analisis data. Pengembangan selanjutnya dapat mengintegrasikan model deteksi objek atau klasifikasi gambar yang telah dilatih, seperti YOLOv8, Convolutional Neural Networks (CNN) kustom, EfficientNet, atau MobileNet. Dengan integrasi ini, dashboard akan berevolusi dari sekadar alat analisis menjadi sistem klasifikasi sampah real-time. Pengguna dapat mengunggah gambar baru melalui dashboard, dan model AI akan secara instan memprediksi kategori sampah tersebut, memberikan demonstrasi langsung dari kemampuan sistem.

c. Deployment Cloud

Untuk meningkatkan aksesibilitas dan kolaborasi, aplikasi Streamlit direkomendasikan untuk di-deploy ke layanan cloud. Platform seperti Streamlit Community Cloud, Render, Railway, atau Google Cloud Platform (GCP) menawarkan solusi hosting yang efisien. Deployment cloud memungkinkan dashboard diakses secara online melalui browser web dari mana saja, memfasilitasi berbagi insight dengan pemangku kepentingan dan mendukung kolaborasi tim yang lebih luas.

d. Pengembangan Dataset Skala Besar

Untuk meningkatkan robustness dan akurasi model klasifikasi di lingkungan dunia nyata, pengumpulan data tambahan sangat dianjurkan. Dataset harus diperluas dengan memasukkan gambar sampah yang diambil dari berbagai kondisi lingkungan (misalnya, dalam ruangan, luar ruangan, latar belakang yang kompleks), variasi pencahayaan (terang, redup, bayangan), dan sudut pengambilan gambar yang beragam. Dataset skala besar yang lebih representatif akan menghasilkan model AI yang lebih andal dan siap untuk diimplementasikan dalam sistem pengelolaan sampah skala industri.